

Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación

Laboratorio 5

Clasificación de tweets usando minería de texto

Informe final: análisis exploratorio, clasificación y análisis de sentimiento

Curso: CC3084 - Data Science

Integrantes: Milton Polanco

Osman de León

Repositorio: GitHub - Lab-MineriayAnalysis

Fecha: 30 de agosto de 2026

Resumen

Se analizaron 7,613 tweets etiquetados para determinar si describen un desastre real. Después de limpiar el texto, se estudiaron unigramas, bigramas, trigramas, nubes de palabras y cruces con *keyword*. Se compararon Naive Bayes, regresión logística y SVM lineal con validación cruzada estratificada. El mejor resultado final fue TF-IDF de unigramas y bigramas con regresión logística.

82.34% exactitud	0.7822 F1	73.85% recall de desastre	7,613 tweets etiquetados
----------------------------	---------------------	-------------------------------------	------------------------------------

VADER mostró que los tweets de desastre real son más negativos, pero añadir la negatividad como predictor redujo F1 en 0.27 puntos porcentuales. Por lo tanto, la función final usa solamente la representación TF-IDF del texto.

Objetivos

- Describir y preprocesar el conjunto de datos.
- Analizar frecuencias y probabilidades de n-gramas.
- Comparar y seleccionar varios clasificadores con métricas adecuadas.
- Crear una función que reciba un tweet sin preprocesar.
- Clasificar el sentimiento, estudiar los tweets extremos y evaluar la variable de negatividad.

1. Datos y análisis exploratorio

El conjunto de entrenamiento contiene 7,613 filas y cinco columnas: `id`, `keyword`, `location`, `text` y `target`. El archivo de prueba de Kaggle contiene 3,263 filas sin la etiqueta. `keyword` tiene 61 nulos (0.80%) y `location` tiene 2,533 (33.27%). Además, las 3,341 ubicaciones distintas no están estandarizadas; por eso no se usan como entrada directa del modelo.




Figura 1. Distribución de la variable objetivo.

Como se observa en la Figura 1, la clase 0 representa 57.0% y la clase 1, 43.0%. El desbalance es leve; se mantienen las proporciones mediante particiones estratificadas y se usa F1 junto con exactitud.




Figura 2. Distribución de longitud y palabras por categoría.

Los tweets de desastre real son ligeramente más largos. La diferencia describe el conjunto, aunque no se añade como columna separada porque la representación TF-IDF ya captura buena parte del contenido y la extensión del texto.




Figura 3. Keywords con menor y mayor tasa de desastre.

Algunas palabras clave tienen tasas muy diferentes, pero existen términos ambiguos usados tanto literalmente como en bromas o metáforas. Una regla basada solo en *keyword* sería frágil. Además, la función solicitada debe recibir únicamente un tweet, de manera que el modelo final se entrena con `text`.

2. Limpieza y preprocesamiento

1. Conversión a minúsculas.
2. Eliminación de URL y menciones.
3. Eliminación del símbolo #, conservando la palabra del hashtag.
4. Eliminación de emojis y caracteres no ASCII para TF-IDF.
5. Eliminación de números, excepto 911.
6. Eliminación de signos de puntuación y apóstrofes.
7. Eliminación de stopwords en inglés mediante NLTK.
8. Eliminación de tokens de un carácter y espacios repetidos.

Decisión sobre 911. Se conserva porque puede indicar una llamada de emergencia. Una prueba automática verifica que “@uvg Call 911! Send 2 medics <https://x.com>” se transforme en “call 911 send medics”.

No se aplicó stemming ni lematización. Las flexiones pueden aportar matices y el vocabulario sigue siendo manejable. Para sentimiento se usa el texto original: VADER aprovecha mayúsculas, puntuación, emoticones y negaciones, por lo que aplicar la misma limpieza agresiva eliminaría información afectiva.

3. N-gramas: frecuencias y probabilidades

Para cada categoría se contó cada n-grama y se calculó su probabilidad empírica: $P(g|c) = \text{frecuencia de } g \text{ en } c / \text{total de n-gramas en } c$. Así se comparan categorías de distinto tamaño.

Unigramas principales

La Tabla 1 muestra los diez unigramas con mayor frecuencia y su probabilidad empírica dentro de cada categoría.

Tabla 1. Unigramas principales por categoría.

No desastre

N-grama	Frecuencia	Probabilidad
like	253	0.00699
im	244	0.00674
amp	193	0.00533
new	171	0.00472
get	163	0.00450
dont	141	0.00389
one	129	0.00356
body	113	0.00312
via	99	0.00273
would	97	0.00268

Desastre real

N-grama	Frecuencia	Probabilidad
fire	181	0.00597
news	138	0.00456
via	121	0.00399
disaster	117	0.00386
california	111	0.00366
suicide	110	0.00363
amp	109	0.00360
police	107	0.00353
people	105	0.00347
killed	93	0.00307





Figura 4. Frecuencia de los 20 unigramas principales por categoría.

fire encabeza los desastres reales y **like** los no desastres. Entre los 100 unigramas más frecuentes de cada clase hay 26 palabras compartidas: amp, back, burning, could, death, dont, emergency, fire, first, get, im, like, man, may, new, news,

one, people, rt, say, still, today, us, via, video, world. Estos términos tienen menor capacidad discriminativa por sí solos y justifican incorporar contexto.

Bigramas principales

La Tabla 2 presenta los bigramas más frecuentes de cada categoría.

Tabla 2. Bigramas principales por categoría.

No desastre

N-grama	Frecuencia	Probabilidad
cross body	38	0.00119
liked video	34	0.00107
full read	28	0.00088
body bag	27	0.00085
body bagging	23	0.00072
burning buildings	23	0.00072
quarantine offensive	21	0.00066
body bags	21	0.00066
looks like	21	0.00066
reddit quarantine	21	0.00066

Desastre real

N-grama	Frecuencia	Probabilidad
suicide bomber	59	0.00218
northern california	41	0.00152
oil spill	38	0.00141
burning buildings	36	0.00133
suicide bombing	34	0.00126
california wildfire	34	0.00126
bomber detonated	30	0.00111
homes razed	29	0.00107
confirmed mh370	29	0.00107
razed northern	28	0.00104





Figura 5. Frecuencia de los 15 bigramas principales por categoría.

Los bigramas agregan contexto mediante expresiones como **suicide bomber**, **oil spill** y **northern california**. Los trigramas se exploraron en el notebook, pero su frecuencia fue baja y no mejoraron la validación: los tweets son cortos y las secuencias de tres palabras quedan demasiado dispersas.



Figura 6. Nubes de palabras para no desastre y desastre real.

4. Modelos de clasificación

Se reservó 20% de los datos como prueba, usando `random_state=42` y estratificación. El 80% restante se evaluó mediante validación cruzada estratificada de cinco particiones. Predecir siempre la clase mayoritaria produce un baseline cercano a 57%; sirve como referencia mínima. TF-IDF disminuye el peso de términos presentes en casi todos los documentos; los unigramas y bigramas representan palabras y parte de su contexto.

La Tabla 3 compara los modelos iniciales mediante las métricas promedio de validación cruzada.

Tabla 3. Comparación de modelos mediante validación cruzada estratificada.

Modelo	Exactitud	Precisión	Recall	F1	Desv. F1
Naive Bayes + conteos (1,2)	0.7957	0.8154	0.6790	0.7406	0.0116
Regresión logística + TF-IDF (1,2)	0.7966	0.8293	0.6641	0.7372	0.0109
Regresión logística + TF-IDF (1,3)	0.7959	0.8274	0.6645	0.7367	0.0121
SVM lineal + TF-IDF (1,2)	0.7764	0.7558	0.7096	0.7316	0.0156

Naive Bayes obtuvo el mejor F1 inicial (0.7406). La regresión logística quedó cerca, permite estimar probabilidades y se ajustó dentro de los datos de entrenamiento. La búsqueda probó $C=\{0.5, 1, 2\}$, unigramas frente a unigramas/bigramas, `min_df={1,2}` y vocabularios de 10,000 o 20,000 características. La mejor configuración fue $C=2$, `ngram_range=(1,2)`, `min_df=2` y 10,000 características, con F1 promedio de 0.7424.

0.8234 exactitud	0.8313 precisión	0.7385 recall	0.7822 F1
----------------------------	----------------------------	-------------------------	---------------------

Figura 7. Matriz de confusion en el 20% de prueba




Figura 7. Matriz de confusión del modelo final en el 20% reservado.

El modelo clasifica correctamente 771 no desastres y 483 desastres. Los 171 falsos negativos son el error más importante. En una aplicación de alertas podría bajarse el umbral para elevar recall, aceptando más falsos positivos.

Función para tweets nuevos

```
def clasificar_tweet(tweet):
    texto_limpio = limpiar_texto(tweet)
    clase = modelo_produccion.predict([texto_limpio])[0]
    prob = modelo_produccion.predict_proba([texto_limpio])[0, 1]
    return {"clasificacion": "Desastre real" if clase else "No desastre",
            "target": int(clase), "probabilidad_desastre": round(prob, 4)}
```

La función recibe texto crudo y aplica el mismo preprocesamiento del entrenamiento. “Wildfire forces families to evacuate near the highway” se clasificó como desastre con probabilidad 0.9654; “My homework is a complete disaster lol” como no desastre con probabilidad de desastre 0.2367; y “Emergency crews rescue people after severe flooding” como desastre con probabilidad 0.8893.

5. Análisis de sentimiento

Se empleó VADER, un método basado en léxico y reglas creado para texto breve de redes sociales. Se clasificó como positivo un $\text{compound} \geq 0.05$, negativo un $\text{compound} < -0.05$ y neutro el intervalo intermedio. Los emoticones se conservaron en este análisis.

Además, cada palabra se consultó en el léxico: valencia mayor que cero se contó como positiva, menor que cero como negativa y sin valencia asignada como neutra. La Tabla 4 resume esos conteos por tweet. La clasificación final usa compound porque también incorpora negaciones, intensificadores, mayúsculas, puntuación y emoticones.

Tabla 4. Promedio de palabras positivas, negativas y neutras según la clasificación de VADER.

Sentimiento	Promedio positivas	Promedio negativas	Promedio neutras
Negativo	0.36	1.66	15.54
Neutro	0.16	0.12	15.41
Positivo	1.53	0.49	15.94

La Tabla 5 cruza la clasificación de sentimiento con la categoría de desastre.

Tabla 5. Cantidad de tweets por sentimiento y categoría de desastre.

Categoría	Negativo	Neutro	Positivo
No desastre	1846	1133	1363
Desastre real	1861	880	530




Figura 8. Sentimiento y distribución de compound por categoría.

En el conjunto completo se encontraron 3,707 tweets negativos, 2,013 neutros y 1,893 positivos. En desastre real, 56.89% son negativos y 16.20% positivos; en no desastre, los porcentajes son 42.52% y 31.39%, respectivamente.

La Tabla 6 resume las diferencias de sentimiento entre ambas categorías.

Tabla 6. Resumen de sentimiento por categoría de desastre.

Categoría	Tweets	Compound promedio	Mediana	Negatividad promedio	% negativos	% positivos
No desastre	4342	-0.0606	0.0000	0.1323	42.51	31.39
Desastre real	3271	-0.2646	-0.3182	0.1736	56.89	16.20

Respuesta: los tweets de desastre real sí son más negativos. Su compound promedio es -0.2646 frente a -0.0606, y sus medianas son -0.3182 y 0.0000. La prueba unilateral de Mann-Whitney obtuvo $U=5,335,958.5$ y $p=8.67e-79$. El tamaño de efecto fue moderado (d de Cohen=-0.458). Existe una diferencia clara, aunque las distribuciones se solapan.

6. Tweets con sentimiento extremo

Diez tweets más negativos

La Tabla 7 presenta los diez valores más bajos de **compound**.

Tabla 7. Diez tweets con menor puntuación de sentimiento.

ID	Categoría	Compound	Tweet
10689	No desastre	-0.9883	wreck? wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck?
9172	Desastre real	-0.9686	@Abu_Baraa1 Suicide bomber targets Saudi mosque at least 13 dead - Suicide bomber targets Saudi mosque at least 13 dead\nThis is ridiculous
9166	Desastre real	-0.9623	Suicide bomber kills 15 in Saudi security site mosque - A suicide bomber killed at least 15 people in an attack on... http://t.co/FY0r9o7Xsl
9137	Desastre real	-0.9595	? 19th Day Since 17-Jul-2015 -- Nigeria: Suicide Bomb Attacks Killed 64 People; Blamed: Boko Haram [L.A. Times/AP] http://t.co/O2cdKpSDfp
9159	Desastre real	-0.9552	17 killed in Sâ Arabia mosque suicide bombing\nA suicide bomber attacked a mosque in Aseer south-western Saudi... http://t.co/pMTQhiVsXX
4213	No desastre	-0.9549	at the lake \n*sees a dead fish*\nme: poor little guy i wonder what happened\nashley: idk maybe it drowned\n wtf ????????
682	Desastre real	-0.9538	illegal alien released by Obama/DHS 4 times Charged With Rape & Murder of Santa Maria CA Woman Had Prior Offenses http://t.co/MqP4hF9GpO
2225	Desastre real	-0.9524	Bomb Crash Loot Riot Emergency Pipe Bomb Nuclear Chemical Spill Gas Ricin Leak Violence Drugs Cartel Cocaine Marijuana Heroine Kidnap Bust
9765	Desastre real	-0.9500	Bomb head? Explosive decisions dat produced more dead children than dead bodies trapped tween buildings on that day in September there
9940	Desastre real	-0.9493	@cspan #Pres. Mr. President you are the biggest terrorist and trouble maker in the world. You create terrorist you sponsor terrorist.

Ocho de estos tweets tienen **target=1** y dos tienen **target=0**. El caso más negativo repite *wreck* y muestra que VADER mide tono, no si el evento es real.

Diez tweets más positivos

La Tabla 8 presenta los diez valores más altos de **compound**.

Tabla 8. Diez tweets con mayor puntuación de sentimiento.

ID	Categoría	Compound	Tweet
10028	No desastre	0.9730	Check out 'Want Twister Tickets AND A VIP EXPERIENCE To See SHANIA? CLICK HERE:' at http://t.co/3GEROQ49o1 \nI would Love Love Love!! To win
9345	No desastre	0.9564	@thoutaylorbrown I feel like accidents are just drawn to you but I'm happy you've survived all of them. Hope you're okay!!!
8989	Desastre real	0.9471	Todayâ's storm will pass; let tomorrowâ's light greet you with a kiss. Bask in this loving warmth; let your soul return to bliss.
4541	No desastre	0.9423	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting. Have a great run.
4844	No desastre	0.9423	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting. Have a great run.

ID	Categoría	Compound	Tweet
9710	No desastre	0.9394	Maaaaan I love Love Without Tragedy by @rihanna I wish she made the whole song
8994	No desastre	0.9376	Free Ebay Sniping RT? http://t.co/B231UI1O1K Lumbar Extender Back Stretcher Excellent Condition!! ? Please Favorite & Share
3525	Desastre real	0.9356	@Raishimi33 :) well I think that sounds like a fine plan where little derailment is possible so I applaud you :)
1453	No desastre	0.9345	I'm not a Drake fan but I enjoy seeing him body-bagging people. Great marketing lol.
9386	No desastre	0.9344	@duchovbutt @Starbuck_Scully @MadMakNY @davidduchovny yeah we survived 9 seasons and 2 movies. Let's hope for the good. There's hope ??????

Ocho pertenecen a `target=0` y dos a `target=1`. Un tweet puede usar vocabulario de tormenta o accidente y aun así expresar esperanza o alivio.

7. Variable de negatividad

Se creó **negatividad** con la proporción **neg** de VADER, entre 0 y 1. Para comparar justamente, se conservaron los mismos índices de entrenamiento y prueba, el mismo vocabulario TF-IDF y la misma regresión logística. La única diferencia fue añadir esta columna a la matriz dispersa. La Tabla 9 muestra la comparación directa.

Tabla 9. Métricas del modelo antes y después de agregar negatividad.

Modelo	Exactitud	Precisión	Recall	F1	Cambio F1
TF-IDF	0.8234	0.8313	0.7385	0.7822	0.0000
TF-IDF + negatividad	0.8221	0.8330	0.7324	0.7795	-0.0027




Figura 9. Comparación del modelo antes y después de agregar negatividad.

Respuesta: la negatividad no mejoró el clasificador. La exactitud bajó 0.13 puntos porcentuales y F1 bajó 0.27. TF-IDF ya incluye palabras afectivas como *killed*, *death*, *bomb* y *love*; por tanto, el puntaje de VADER agrega información redundante.

8. Conclusiones y limitaciones

1. Las clases están razonablemente balanceadas. La ubicación no se utilizó por sus nulos y falta de estandarización.
2. La limpieza conserva la palabra de los hashtags y el número 911. Para sentimiento se usa el texto original para conservar señales afectivas.
3. Los bigramas agregan contexto útil. Los trigramas son demasiado dispersos y no mejoraron la validación.
4. TF-IDF con regresión logística obtuvo 82.34% de exactitud y $F1=0.7822$.
5. Los desastres reales son más negativos en promedio, pero el sentimiento no equivale a la etiqueta de desastre.
6. Añadir negatividad no mejoró el modelo, por lo que la función final usa solo el texto.

El modelo lineal no comprende completamente sarcasmo, ironía ni conocimiento del mundo. VADER puede sobrevalorar repeticiones o palabras aisladas, y algunos caracteres del archivo original presentan problemas de codificación. Antes de utilizar el sistema en emergencias reales se necesitarían datos recientes, calibración y un análisis explícito del costo de los falsos negativos.

Reproducibilidad

El notebook `notebooks/Laboratorio5.ipynb` contiene el proceso completo y fue ejecutado desde cero. Se fijó `random_state=42`, se dejó el 20% para prueba y se guardaron las figuras y tablas derivadas en `reporte/`. Las dependencias están especificadas en `requirements.txt`.

Referencias

1. Kaggle. *Natural Language Processing with Disaster Tweets*. kaggle.com/competitions/nlp-getting-started.
2. Hutto, C. J. y Gilbert, E. (2014). *VADER: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text*. *Proceedings of ICWSM*, 8(1), 216-225. doi:10.1609/icwsml.v8i1.14550.
3. NLTK Project. *Sample usage for sentiment*. nltk.org/howto/sentiment.html.
4. Scikit-learn Developers. *Working with text data*. scikit-learn.org.
5. Jurafsky, D. y Martin, J. H. *Speech and Language Processing*. web.stanford.edu/~jurafsky/slp3/.