

Universidad del Valle de Guatemala  
Facultad de Ingeniería  
Departamento de Ciencias de la Computación

---

## Laboratorio 5

Clasificación de tweets usando minería de texto

Avance: descripción de datos, preprocesamiento, unigramas,  
bigramas y modelo preliminar de clasificación

---

**Curso:** CC3084 – Data Science  
**Integrantes:** Milton Polanco  
Osman de León  
**Fecha:** 27 de agosto de 2026

## 1. Introducción

Este documento presenta el avance del Laboratorio 5, cuyo objetivo final es construir un modelo que clasifique si un tweet se refiere a un desastre real o no, utilizando el dataset *Natural Language Processing with Disaster Tweets* de Kaggle. En esta entrega se documentan la carga y descripción de los datos, el proceso de limpieza y preprocesamiento de texto, el análisis de frecuencia de palabras (unigramas y bigramas), un análisis exploratorio de los datos, y la descripción de un modelo preliminar de clasificación. La selección del mejor modelo, la función de clasificación para tweets nuevos, el análisis de sentimiento y el informe final se presentan en la entrega del 30 de agosto de 2026.

Todo el procesamiento se realizó en Python, dentro de un *Jupyter Notebook*, utilizando las librerías `pandas`, `nlTK`, `scikit-learn` y `wordcloud`. El código completo, reproducible, se encuentra en el repositorio del proyecto.

## 2. Descripción del dataset

El conjunto de entrenamiento está compuesto por 7,613 tweets con cinco columnas: `id`, `keyword` (palabra clave del tweet, con un 0.8 % de valores nulos), `location` (ubicación de origen, con un 33 % de valores nulos y sin estandarizar), `text` (el texto del tweet) y `target` (1 = desastre real, 0 = no lo es).

La variable objetivo está razonablemente balanceada: 57.0 % de los tweets corresponden a la clase 0 (no desastre) y 43.0 % a la clase 1 (desastre real), por lo que no se considera necesario aplicar técnicas de balanceo de clases para el modelo preliminar. Dado el alto porcentaje de nulos en `location` y su naturaleza de texto libre no estandarizado, se decidió no utilizarla como predictor en esta etapa del laboratorio.

## 3. Limpieza y preprocesamiento de los datos

Se diseñó una función de limpieza de texto que aplica, en orden, los siguientes pasos:

1. **Conversión a minúsculas**, para que variantes como “Fire” y “fire” se traten como la misma palabra.
2. **Eliminación de URLs**, ya que no aportan significado semántico.
3. **Eliminación de menciones** (@usuario), consideradas ruido.
4. **Eliminación del símbolo # conservando la palabra del hashtag**, dado que el contenido del hashtag suele ser temáticamente relevante (por ejemplo, #earthquake se conserva como earthquake).
5. **Eliminación de emojis y emoticones** (caracteres fuera del rango ASCII estándar).
6. **Eliminación de números, con excepción de “911”**: se decidió conservar “911” por su fuerte asociación con llamadas de emergencia reales, mientras que otros números (fechas, cantidades) generalmente no aportan valor discriminativo.
7. **Eliminación de signos de puntuación y apóstrofes**.
8. **Eliminación de stopwords en inglés** (artículos, preposiciones, conjunciones), usando el corpus de NLTK.

## 9. Normalización de espacios en blanco.

Como ejemplo, el tweet original *“I’m on the highway near the accident, calling 911 right now!!”* se transforma, tras el preprocesamiento, en *“highway near accident calling 911 right”*, conservando las palabras con carga semántica y el número de emergencia.

## 4. Frecuencia de palabras: unigramas y bigramas

Se calculó la frecuencia de palabras (unigramas) por separado para los tweets de desastre real y de no-desastre. La Figura 1 muestra las 20 palabras más frecuentes en cada categoría.




Figura 1: Top 20 palabras más frecuentes por categoría, tras el preprocesamiento.

En los tweets de desastre real predominan palabras muy asociadas a eventos catastróficos concretos (**fire**, **flood**, **disaster**, **killed**, **california**, **storm**), mientras que en los de no-desastre predominan palabras genéricas o usadas en sentido figurado (**like**, **new**, **via**, **body**). Esto sugiere que un modelo basado en frecuencia de palabras ya captura señal útil, aunque el reto principal está en los tweets que usan palabras de “desastre” en sentido no literal (ironía, metáfora), donde el contexto puede ayudar.

Por esta razón se calcularon también los bigramas más frecuentes por categoría (Figura 2).

Los bigramas capturan combinaciones de dos palabras como **suicide bomber**, **northern california** u **oil spill**, mucho más específicas y menos ambiguas que las palabras sueltas que las componen. Esto es clave para resolver casos donde una palabra individual (por ejemplo, *fire* en “I’m on fire today lol” frente a *wildfire*) es ambigua fuera de contexto. Se considera que sí vale la pena explorar bigramas para el modelo de clasificación; se evaluará más adelante si los trigramas aportan una mejora adicional significativa, aunque dado que los tweets son cortos (en promedio, pocas palabras tras la limpieza), es probable que generen features muy dispersas con poco beneficio marginal.

## 5. Análisis exploratorio de los datos (EDA)

Como parte del análisis exploratorio se identificó la palabra más repetida en cada categoría, se generó una nube de palabras por categoría, un histograma de las palabras más frecuentes a nivel global, y se revisaron las palabras (y **keywords**) con presencia en ambas categorías.




Figura 3: Nube de palabras para tweets de desastre real (izquierda) y de no-desastre (derecha).

La nube de palabras (Figura 3) confirma visualmente el patrón detectado con las frecuencias: en desastre real dominan términos concretos de catástrofes, mientras que en no-desastre predominan palabras de uso cotidiano y expresiones en sentido figurado.

Al comparar las 100 palabras más frecuentes de cada categoría, se encontró un conjunto de palabras en común entre ambas clases: conectores, verbos genéricos y palabras muy usadas en general (por ejemplo, **people**, **via**, **will**, **new**). Lo mismo ocurre con algunas **keywords** ambiguas (como **wrecked**, **deluge** o **panic**), que se usan tanto en tweets de desastre real como en tweets con esa palabra en sentido figurado o de broma. Esto refuerza la idea de que el contexto (bigramas), y no solo la palabra aislada, es clave para separar bien ambas clases.

También se revisó la distribución de la variable objetivo (Figura 5) y la longitud de los tweets, confirmando el balance de clases descrito en la Sección 2.

## 6. Descripción del modelo preliminar de clasificación

Dado que el problema requiere capturar tanto palabras individuales relevantes como combinaciones de palabras (contexto), se planteó representar cada tweet mediante **TF-IDF** (*Term Frequency – Inverse Document Frequency*), considerando unigramas y bigramas (`ngram_range=(1,2)`), lo cual




Figura 4: Histograma de las 25 palabras más frecuentes en todo el dataset.




Figura 5: Distribución de la variable objetivo (**target**).

permite que el modelo aproveche tanto palabras sueltas discriminativas (**fire**, **killed**) como combinaciones con contexto (**suicide bomber**).

Como modelo preliminar se probaron dos algoritmos simples y rápidos, típicos para clasificación de texto:

- **Regresión Logística:** buen *baseline* lineal para texto disperso de alta dimensión (TF-IDF).
- **Naive Bayes Multinomial:** algoritmo clásico para clasificación de texto, funciona bien con conteos de palabras.

Se realizó una partición 80/20 (entrenamiento/validación), estratificada por la variable objeti-

vo, para obtener una primera métrica de referencia. Los resultados preliminares se resumen en el Cuadro 1.

Cuadro 1: Resultados preliminares sobre el conjunto de validación (20 %).

| Modelo                  | Accuracy | F1-score |
|-------------------------|----------|----------|
| Regresión Logística     | 0.8273   | 0.7821   |
| Naive Bayes Multinomial | 0.8168   | 0.7593   |

Ambos modelos superan claramente el *baseline* ingenuo de predecir siempre la clase mayoritaria (57 %), lo que confirma que la representación TF-IDF con unigramas y bigramas captura señal útil para este problema. Este es un resultado **preliminar**: en la entrega final se explorarán otros algoritmos (por ejemplo, SVM o *ensembles*), se incluirá la variable **keyword**, se ajustarán hiperparámetros y se seleccionará el mejor modelo con base en métricas apropiadas dado el leve desbalance de clases (F1-score, en lugar de únicamente *accuracy*).

## 7. Conclusiones del avance

- Se cargaron y describieron los datos: 7,613 tweets de entrenamiento, clases balanceadas (57 %/43 %), y una alta proporción de valores nulos en **location** (33 %).
- Se aplicó un pipeline de limpieza de texto que incluye minúsculas, eliminación de URLs, menciones, símbolos de hashtag, emojis, puntuación, números (conservando “911”) y *stopwords*.
- Se calcularon las frecuencias de unigramas y bigramas por categoría, identificando palabras y combinaciones discriminativas para la clasificación.
- Se realizó un análisis exploratorio adicional (nube de palabras, histograma global, palabra más repetida por categoría y palabras/**keywords** comunes a ambas clases).
- Se planteó y probó un modelo preliminar (TF-IDF + Regresión Logística / Naive Bayes) que ya obtiene resultados superiores al *baseline* ingenuo (accuracy de 82.7 % con Regresión Logística).

Para la entrega final (30 de agosto de 2026) queda pendiente: completar el análisis exploratorio con cruces adicionales de variables, seleccionar y evaluar rigurosamente el mejor modelo de clasificación, construir la función de clasificación para tweets nuevos sin preprocesar, realizar el análisis de sentimiento (positivo/negativo/neutro), construir la variable de “negatividad” del tweet y reentrenar el modelo con ella, y redactar el informe final con todos los hallazgos.